



# Técnicas Inteligentes

---

## Redes Neurais Artificiais

### Aula 02

Leonardo Willer de Oliveira

Juiz de Fora, 15 de Maio de 2017

## Referências



- Haykin, S., *Neural Networks, A Comprehensive Foundation*, Prentice Hall, 1999.
- Haykin, S., *Redes Neurais, Teoria e Prática*, Bookman, 2001.
- Luiz P. Calôba, *Uma pequena introdução às Redes Neurais Artificiais e Aplicações*, Curso compacto – Informativo, Gramado, 2005.



## *Camada de Kohonen*

---

- Rede ART, Rede *Counterpropagation*
  - ✓ Aprendizado cego, não supervisionado, auto-organizáveis
  - ✓ Plasticidade
  - ✓ Classificadores por similaridade
  - ✓ Aplicações *on-line*
  - ✓ Biologicamente plausível (córtex auditivo)





## *Camada de Kohonen*

---

- Aplicações
  - ✓ Reconhecimento de padrões
  - ✓ Estatística de sinais
  - ✓ Memórias associativas
  - ✓ Filtragem não-linear
  - ✓ Compressão de dados
  - ✓ Mapas auto-organizáveis

# Camada de Kohonen


- Classificação por similaridade



$$\underline{w}_i = E_{\underline{xj} \in C_i} [\underline{xj}] = \frac{1}{N_i} \cdot \sum_{\underline{xj} \in C_i} \underline{xj}$$

## Camada de Kohonen


- Critério: Padrão mais similar à entrada



$$\text{Se } |\underline{x} - \underline{w}_i|^2 < |\underline{x} - \underline{w}_j|^2 \quad \forall j \neq i \quad \longrightarrow \quad \underline{x} \in C_i$$

## Camada de Kohonen


- Critério: Similaridade mínima



$$\text{Se } |\underline{x} - \underline{w}_i|^2 < r_0^2 \quad \longrightarrow \quad \underline{x} \in C_i \quad r_0 - \text{raio de similaridade}$$

## Camada de Kohonen


- Neurônio medidor de similaridade



Considerando  $|\underline{x}| = 1$

$$|\underline{w}_i| = 1$$

$$b_i = 0$$



$$u_i = 1 - \frac{d_i^2}{2} \text{ sendo } d_i = |\underline{x} - \underline{w}_i|$$

$u_i$ : similaridade entre  $\underline{x}$  e  $\underline{w}_i$   $u_i \in [-1, +1]$




## Camada de Kohonen

### ■ Winner-takes-all

$$u_i = \underline{x} \underline{w}_i = 1 - \frac{d_i^2}{2}$$

$$d_i = |x - w_i|$$



$$y_i = 1 \text{ se } u_i > u_j \forall j \neq i$$

$y_i = 0$  caso contrário

Classe  $C_i$



Padrão  $w_i$




Indicador  $y_i$



Se  $y_i = 1$   $\underline{x} \in C_i$

Camada de Kohonen



## Camada de Kohonen


### ■ Treinamento Supervisionado e Não-Supervisionado

Se  $\underline{x}(n) \in C_i$  ou  $y_i = 1$

$$\underline{w}_i(n+1) = \underline{w}_i(n) + \alpha [\underline{x}(n) - \underline{w}_i(n)]$$

$$\underline{w}_j(n+1) = \underline{w}_j(n) \quad \forall j \neq i$$

$\underline{n}$  : iteração  $n$




Convergência

$$E[\underline{\Delta w}] = \underline{0}$$

Observação:  $\alpha$  pode ser atualizado durante o processo iterativo

Exemplo  $\alpha_n = 0,9 \cdot (1 - n/1000)$

## Camada de Kohonen Aumentada



Se  $y_i = 1$

$\underline{x} \in C_i$  pelos critérios "padrão mais similar" e "similaridade mínima" ( $r_0$ )

Se  $y_0 = 1$

$\underline{x}$  não atende a similaridade mínima para nenhuma classe

$$u_i = 1 - \frac{d_i^2}{2} \text{ sendo } d_i = |x - w_i|$$

$$u_0 = 1 - \frac{r_0^2}{2}$$




# ART

---

- Teoria de Ressonância Adaptativa  
(*Adaptive Resonance Theory*)
  - ✓ Classificador
  - ✓ Aprendizado não-supervisionado
  - ✓ Semelhanças com o modelo de Kohonen no armazenamento de padrões

# ART



- Similaridade mínima exigida

Se  $\underline{y}_0 = 1$   $\underline{x} \notin C_i \quad \forall i$

Ativar um neurônio  $i$  desativado

$$\underline{w}_i(n+1) = \underline{x}(n)$$

$$\underline{w}_j(n+1) = \underline{w}_j(n) \quad \forall j \neq i$$


Se  $\underline{y}_i = 1$

Treinar o neurônio  $i$  vencedor

$$\underline{w}_i(n+1) = \underline{w}_i(n) + \alpha [\underline{x}(n) - \underline{w}_i(n)]$$

$$\underline{w}_j(n+1) = \underline{w}_j(n) \quad \forall j \neq i$$

# ART



## ■ Esquecimento

Se  $y_i = 0$  por N entradas consecutivas:

✓ Guardar informação (lembrança) para o futuro

✓ Desativar neurônio  $\underline{w}_i = 0$   $\underline{m}_k = \underline{w}_i$

## ■ Lembrança

Se  $y_j = 0$ :

✓ Ativar neurônio

✓ Existe lembrança?  $\underline{x}^t \underline{m}_k > u_0 \rightarrow \underline{w}_j = \underline{m}_k$

✓ Não há lembrança?  $\underline{w}_j = \underline{x}$





## ***Redes de Hopfield***

---

- Redes realimentadas
  - ✓ Problemas de otimização combinatória
  - ✓ Binárias
  - ✓ Supervisionadas
  - ✓ Baseadas no conceito de energia da rede
  - ✓ Objetivo: minimizar a energia ou a oscilação entre estados na saída

# Redes Retroalimentadas

Camada de Entrada    Camada Oculta    Camada de Saída





# Redes de Hopfield

- O estado  $y_i$  de um neurônio  $i$  no instante  $t + 1$  é obtido pela seguinte função da soma ponderada das entradas:

$$y_i(t+1) = \text{sgn} \left( \sum_{j=1}^n w_{ij} y_j(t) - \theta_i \right)$$


$n$  : número de associações  
 $\theta$  : limiar

A função  $\text{sgn}$  pode ser definida por:

$$\text{sgn}(x) = \begin{cases} +1 & \text{se } x \geq 0 \\ -1 & \text{se } x < 0 \end{cases}$$



$$y \in \{-1, +1\}$$



# Redes de Hopfield

■ Pesos

$$w_{ij} \propto y_i y_j$$

$$w_{ij} = \frac{1}{N} y_i y_j$$



$N$  : número de neurônios da rede

Condição de estabilidade de um vetor  $\mathbf{y}$  ( $\theta = 0$ )

$$y_i = \text{sgn} \left( \sum_j w_{ji} y_j \right) \quad \forall \quad i$$

Substituindo  $w_{ij}$  obtém-se

$$y_i = \text{sgn} \left( \sum_j w_{ji} y_j \right) = \text{sgn} \left( \frac{1}{N} \sum_j y_j y_i y_j \right) \quad \forall \quad i$$




# Redes de Hopfield

- Se um  $y_j$  muda, mas a maioria se mantém, o somatório de

$$y_i = \text{sgn}\left(\sum_j w_{ji} y_j\right) = \text{sgn}\left(\frac{1}{N} \sum_j y_j y_i y_j\right) \quad \forall \quad i$$

tende a manter o sinal de  $y_i$ .



$$y_1 = \text{sgn}\left[\frac{1}{4} \cdot (w_{12} \cdot y_2 + w_{13} \cdot y_3 + w_{14} \cdot y_4)\right]$$

Se  $y_4$  muda,  $y_1$  mantém

Recuperação

Distância de Hamming

$$\sum_i \left[ y_i \cdot (1 - y'_i) + (1 - y_i) \cdot y'_i \right]$$



## Redes de Hopfield

- Exemplo: Para a matriz de pesos

$$\mathbf{W} = \begin{pmatrix} 0 & -0,333 & 0,333 \\ -0,333 & 0 & -0,333 \\ 0,333 & -0,333 & 0 \end{pmatrix}$$

Os vetores  $(-1 \ 1 \ -1)^T$  e  $(1 \ -1 \ 1)^T$  são estáveis

$$w_{ij} = \begin{cases} \frac{1}{N} \cdot \sum_{s=1}^p y_i^s \cdot y_j^s & \text{se } i \neq j \\ 0 & \text{se } i = j \end{cases} \quad \begin{array}{l} \text{Regra de Hebb} \\ p : \text{número de padrões} \end{array}$$

Convergência processo iterativo  $\rightarrow y_i(t+1) = y_i(t)$



# *Redes de Hopfield*

---

- Algoritmo de Treinamento: sequencial

Para  $i = 1$  até  $N$

$$y_i = y_i^0$$

Fim\_Para

Repita

Para  $i = 1$  até  $N$

$$y_i^- = y_i$$

$$y_i = \text{sgn}(\sum w_{ij} * y_j, j \neq i)$$

Fim\_Para

Até  $y_i = y_i^-$  para todo  $i \in N$

Fim

# Redes de Hopfield

- A energia associada com o estado do sistema pode ser dada por

$$E = -\frac{1}{2} \left( \sum_i \sum_j w_{ij} \cdot y_i \cdot y_j \right)_{i \neq j}$$

Para uma rede de dimensão  $N$ , considera-se que o nó ' $m$ ' mude o seu estado do valor  $y_m$  para  $y_m'$

A variação de energia resultante pode ser formulada como

$$\begin{aligned} \Delta E = & -\frac{1}{2} ( w_{12}y_1y_2 + \dots + w_{1N}y_1y_N + w_{21}y_2y_1 + \dots + w_{2N}y_2y_N + \dots \\ & + w_{m1}y_m'y_1 + \dots + w_{mN}y_m'y_N + \dots + w_{N1}y_Ny_1 + \dots + w_{N(N-1)}y_Ny_{N-1} ) - \\ & [ -\frac{1}{2} ( w_{12}y_1y_2 + \dots + w_{1N}y_1y_N + w_{21}y_2y_1 + \dots + w_{2k}y_2y_N + \dots \\ & + w_{m1}y_my_1 + \dots + w_{mN}y_my_N + \dots + w_{N1}y_Ny_1 + \dots + w_{N(N-1)}y_Ny_{N-1} ] ) \end{aligned}$$



## Redes de Hopfield

- Manipulando-se a expressão anterior, obtém-se

$$\Delta E = -\frac{1}{2} \cdot y'_m \cdot \sum_i w_{mi} \cdot y_i + \frac{1}{2} \cdot y_m \cdot \sum_i w_{mi} \cdot y_i$$

Como  $y_m = -y'_m$  tem-se:  $\Delta E = y_m \cdot \sum_i w_{mi} \cdot y_i$

Sendo  $y'_m = \text{sgn}\left(\sum_i w_{mi} \cdot y_i\right)$ , para  $\theta = 0$

conclui-se que  $\sum_i w_{mi} \cdot y_i$  tem sinal contrário a  $y_m$

Logo  $\Delta E < 0$ , ou seja, a função energia diminui quando  $y_m \neq y'_m$ .